

FUSION Boot Camp 2026 — סדרת מחברות

הסבר

29th International Conference on Information Fusion

Trondheim, Norway · June 22–26, 2026

מתאם: Dale Blair · מרצים: Blasch, Blair, Govaers, Meyer, Bar-Shalom, Varshney

סדרת מחברות זו מתעדת ומדגימה בקוד את הפיתוחים (developments) שתוארו בקובץ FUSION Boot Camp pdf. 2026. הקובץ עצמו מכיל שני מערכי שקופיות מלאים — המבוא של Erik Blasch ושיעור האמידה (Estimation) של W. Dale Blair — וכן את לוח הזמנים של שבע ההרצאות של ה-Boot Camp.

לוח הזמנים של ה-Boot Camp (22 ביוני 2026)

מרחב	# נושא
Erik Blasch	Introduction to Information Fusion 1
Dale Blair	Estimation in Information Fusion 2
Florian Meyer	Data Association 3
Felix Govaers	Distributed Target Tracking 4
Yaakov Bar-Shalom	Fusion and Association with Attributes/Classification 5
Pramod Varshney	Distributed Inference and Information Fusion 6
Erik Blasch	High-level Fusion 7

מבנה הסדרה

מחברת	תוכן	מבוסס על
00_overview.ipynb	סקירה כללית, לוח זמנים, אינדקס	—
01_introduction_to_information_fusion.ipynb	מושגי יסוד, היסטוריה, מודל JDL/DFIG (רמות 0-5), משוואת ה-Fusion, יתרונות/חסרונות, היררכיית ההיסק	הרצאת Blasch
02_parameter_estimation.ipynb	ML, MAP, MMSE, LSE, WLSE, חסם Cramér-Rao, אמידת הטיה (bias)	הרצאת Blair (חלק א')
03_state_estimation_kalman_filter.ipynb	גזירת מסנן קלמן, predictor-corrector, רעש תהליך DWNA/NCV, מודל CWNA	הרצאת Blair (חלק ב')
04_target_tracking_maneuvering.ipynb	NCV מול NCA, בחירת שונות רעש התהליך, IMM, EKF, ריבוי חיישנים	הרצאת Blair (חלק ג')
05_data_association.ipynb	Gating, GNN, PDA/JPDA, MHT	הרצאת *Meyer
06_distributed_target_tracking.ipynb		

מחברת	תוכן	מבוסס על
	מסנן מידע, track-to-track, Covariance Intersection	הרצאת *Govaers
07_attributes_classification.ipynb	סיווג בייסיאני רצוף, מטריצת בלבול, Dempster-Shafer	הרצאת -Bar *Shalom
08_distributed_inference.ipynb	ROC, כללי Chair, -k-out-of-N, Varshney	הרצאת *Varshney
09_high_level_fusion.ipynb	רמות L2-L5, הערכת מצב/איום, MOP/MOE, hard+soft	הרצאת *Blasch (7)

הערה (*): ההרצאות 3-7 מופיעות בלוח הזמנים אך השקופיות שלהן **אינן** כלולות ב-PDF. מחברות 05-09 הן **מחברות מלוות** המבוססות על הספרות הקנונית של התחום (Bar-Shalom, Blackman & Popoli, Varshney) ועל ההקשר שמספק Blasch במבוא — ולא על שקופיות מקוריות. מחברות 01-04 מבוססות ישירות על שני המערכים שב-PDF.

דרישות הרצה

```
pip install numpy matplotlib
```

כל מחברת עצמאית וניתנת להרצה מתחילתה לסופה (Run All).

```
# בדיקת סביבה
import sys
import numpy as np
import matplotlib
print('Python', sys.version.split()[0])
print('numpy', np.__version__)
print('matplotlib', matplotlib.__version__)
```

```
Python 3.11.15
numpy 2.4.6
matplotlib 3.11.0
```

01 - מבוא ל-Information Fusion

מבוסס על: Erik Blasch, FUSION Boot Camp 2026 — Introduction to Data Fusion

Take-aways של ההרצאה

1. מהו **Data Fusion**? — היתוך מקטין אי-ודאות; הכמת אי-הוודאות היא השונות P (covariance).
2. **שיטות**: רישום נתונים (registration) = קורלציה; היתוך נתונים (fusion) = שיוך נתונים (association).
3. מה **fusion** יכול ולא יכול לעשות: מרחיב כיסוי במרחב/זמן ומקטין עומס נתונים; אינו 'מספר קסם', אינו מתקן נתונים גרועים, ואינו מחליף הסקה אנושית.
4. **ארכיטקטורות**: מודל JDL/DFIG, רמות 0-5 (טקסונומיה); חישה רב-תחומית (חלל, אוויר, סייבר) המשלבת hard (תמונות) ו-soft (טקסט).

א. היסטוריה קצרה של רעיון ה-Fusion

Blasch ממקם את היתוך המידע ברצף היסטורי ארוך של 'איחוד חושים' והסקה:

תקופה	תרומה
יוונים	אפלטון — טענות/אמונות/ראיות; אריסטו — הנשמה כמאחדת חושים
מטריאליזם	דקארט — גוף ונפש; אינטראקציה סיבתית (חומר ותנועה)
1500-1700	קפלר, גלילאו, ניוטון — תנועה ואינטראקציה דינמית
1700	Bayes — אמונות (probability)
1800	ניסויים — תגובה לגירוי
1900	Galton, Pearson — קורלציה (שיוך); William James — איחוד חושים (FUSE)
1960	מסנן קלמן (Kalman Filter)
1990	סדרת הספרים הראשונה על Sensor & Data Fusion

Fusion כמדע: שלושה שערים

- **אונטולוגיה (Ontology)** — מהו 'העולם' ומבניו (הצהרה על מה שקיים; למשל החישה).
- **אפיסטמולוגיה (Epistemology)** — כללי המשחק; כיצד יודעים משהו (כללי ה-fusion).
- **טקסונומיה (Taxonomy)** — סיווג/סמנטיקה של המידע.

ב. סוגי היסק ב-Fusion (Inference) ברמה גבוהה

Inductive	Deductive	Abductive
פעולה מהתבוננות להבנה כללית	גזירת תוצאה מתוך חוק	היסק ההסבר הסביר ביותר לתצפית
כיוון מהפרטי לכללי	מהכללי לפרטי	שילוב יחסים
שיטות Bayes Nets If-then, Hypothesis tests Probability, Bayesian, entropy		

(E. Blasch, P. Valin, E. Bossé, "Measures of Effectiveness for High-Level Fusion," Fusion 2010)

ג. משוואת ה-Fusion המרכזית (Key Fusion Equation)

הטענה המרכזית: **fusion מקטין אי-ודאות**. כאשר ממזגים שתי מדידות בלתי-תלויות של אותו ערך, עם שוניות

$$P_1, P_2$$

(או

$$\sigma_1^2, \sigma_2^2$$

), מתקבל אומדן ממוזג שהשונות שלו קטנה מכל אחת מהן:

$$\frac{1}{P_F} = \frac{1}{P_1} + \frac{1}{P_2} \Rightarrow P_F = \frac{P_1 P_2}{P_1 + P_2}$$

(adapted from Maybeck, 1978). זוהי בדיוק נוסחת מיזוג שני גאוסיאנים — שקולה לעדכון מדידה במסנן קלמן.

דוגמת השקופית: עם

$$\sigma_1^2 = 1$$

-1

$$\sigma_2^2 = 4$$

מתקבל

$$P_F = \frac{1 \cdot 4}{1 + 4} = 0.8$$

, כלומר

$$\sigma_F = \sqrt{0.8} \approx 0.90$$

— קטן מ-

$$\sigma_1 = 1$$

```
import numpy as np
import matplotlib.pyplot as plt

def fuse(x1, P1, x2, P2):
    """מיזוג שני אומדנים גאוסיאניים בלתי-תלויים (סקלר או מטריצה).
    מחזיר את האומדן הממוזג ואת השונות הממוזגת"""
    P1, P2 = np.asarray(P1, float), np.asarray(P2, float)
    if P1.ndim == 0: # סקלר
        PF = (P1 * P2) / (P1 + P2)
        xF = PF * (x1 / P1 + x2 / P2)
        return xF, PF
    PF = np.linalg.inv(np.linalg.inv(P1) + np.linalg.inv(P2)) # מיזוג ע"י מידע (information form)
    xF = PF @ (np.linalg.inv(P1) @ x1 + np.linalg.inv(P2) @ x2)
    return xF, PF

# דוגמת השקופית
xF, PF = fuse(0.0, 1.0, 0.0, 4.0)
print(f'P_F = {PF:.3f}, sigma_F = {np.sqrt(PF):.3f} (sigma_1=1 ו-sigma_2=2)')
```

P_F = 0.800, sigma_F = 0.894 (sigma_1=1 ו-sigma_2=2)


```
# ויזואליזציה: שני גאוסיאנים והגאוסיאן הממוזג
from math import sqrt, pi
```

```

x = np.linspace(-6, 6, 400)
def gauss(x, mu, var):
    return np.exp(-(x-mu)**2/(2*var))/sqrt(2*pi*var)

x1, P1, x2, P2 = -1.5, 1.0, 2.0, 4.0
xf, Pf = fuse(x1, P1, x2, P2)
plt.figure(figsize=(8,4))
plt.plot(x, gauss(x, x1, P1), '--', label=f'1 חיישן:  $\sigma^2=\{P1\}$ ')
plt.plot(x, gauss(x, x2, P2), '--', label=f'2 חיישן:  $\sigma^2=\{P2\}$ ')
plt.plot(x, gauss(x, xf, Pf), 'k', lw=2.5, label=f'ממוזג:  $\sigma^2=\{Pf:.2f\}$ ')
plt.title('Key Fusion Equation – אי-ודאות')
plt.xlabel('value'); plt.ylabel('density'); plt.legend(); plt.grid(alpha=.3)
plt.tight_layout(); plt.show()
print('שים לב: שיא הצפיפות הממוזגת גבוה וצר יותר < שונות קטנה יותר')

```



שים לב: שיא הצפיפות הממוזגת גבוה וצר יותר < שונות קטנה יותר

הקטנת אליפסת השונות (Covariance Ellipse Reduction) – מקרה דו-ממדי

כאשר שני חיישנים מודדים מיקום במישור עם אליפסות שגיאה שונות (למשל רדאר מדויק בטווח ולא בזווית, וחיישן אופטי להפך), המיזוג מצמצם את שטח האליפסה – בדיוק העיקרון שמאחורי טריאנגולציה.

```


def cov_ellipse(P, mean=(0,0), n_std=2.0, **kw):
    vals, vecs = np.linalg.eigh(P)
    t = np.linspace(0, 2*np.pi, 200)
    circle = np.array([np.cos(t), np.sin(t)])
    ell = vecs @ np.diag(n_std*np.sqrt(vals)) @ circle
    return ell[0]+mean[0], ell[1]+mean[1]

P1 = np.array([[4.0, 0.0],[0.0, 0.2]]) # x גס לאורך, y מדויק לאורך
P2 = np.array([[0.2, 0.0],[0.0, 4.0]]) # להפך
xF, PF = fuse(np.zeros(2), P1, np.zeros(2), P2)

plt.figure(figsize=(5,5))
for P, lab, st in [(P1,'1 חיישן','C0--'),(P2,'2 חיישן','C1--'),(PF,'ממוזג','k-')]:
    ex, ey = cov_ellipse(P)

```

```
plt.plot(ex, ey, st, lw=2 if lab=='ממוזג' else 1.2, label=lab)
plt.gca().set_aspect('equal'); plt.legend(); plt.grid(alpha=.3)
plt.title('הקטנת אליפסת השונות ע"י מיזוג'); plt.tight_layout(); plt.show()
print('det(P1)=%.3f det(P2)=%.3f det(P_F)=%.3f (שטח האליפסה הממוזגת קטן בהרבה)'
      % (np.linalg.det(P1), np.linalg.det(P2), np.linalg.det(PF)))
```



det(P1)=0.800 det(P2)=0.800 det(P_F)=0.036 (שטח האליפסה הממוזגת קטן בהרבה)

ד. מודל ה-JDL/DFIG – רמות ה-0-5 Fusion

הטקסונומיה הסטנדרטית לתיאור פונקציות ה-fusion (JDL במקור, הורחב ל-DFIG ב-2006):

רמה שם	תיאור
L0 Sub-object / Signal	רישום ועיבוד אות, חילוך מאפיינים
L1 Object assessment	גילוי, זיהוי (classification), ומעקב (tracking) של עצמים
L2 Situation assessment	אמידת יחסים בין ישויות; תמונת מצב
L3 Threat / Impact assessment	אמידת איום, כוונה (intent), והשלכות עתידיות
L4 Process refinement	ניהול חיישנים ובקרה (sensor management)
L5 User refinement	האדם בלולאה – הצגה, אינטראקציה, החלטה

(DFIG (Data Fusion Information Group), Situation Assessment", J. of Adv. in Info. Fusion, Dec")
(.2006)

מה אפשר היום (Can Do): רישום תמונה (L0), גילוי/זיהוי ומעקב מטרות לא-מתמרנות בסביבה דלילה (L1), הסקה אוטומטית מוגבלת ב-L2/L3, אופטימיזציה לחיישנים תואמים ב-L4, ואספקת אומדנים לאדם ב-L5.

מה עדיין קשה (Can NOT Do): מעקב מדויק אחר מטרות מתמרנות בצפיפות גבוהה, התקרבות ליכולת ההסקה האנושית, מידול מדויק של כוונה, ואופטימיזציה של חיישנים לא-תואמים מבוזרים.

```
# מרמת אות לרמת ידע – (Inference Hierarchy) היררכיית ההיסק
levels = [
    ('L0 אות', 'Signal Processing', 'גילוי, מאפיינים'),
    ('L1 עצם', 'Estimation', 'Kalman/Bayesian, MAP'),
    ('L2 מצב', 'Decision-level', 'Bayesian nets, fuzzy, NN'),
    ('L3 איום', 'Knowledge-based', 'מערכות מומחה, CBR'),
    ('L4/L5 ניהול', 'Control / User', 'sensor mgmt, human-in-loop'),
]
print(f"{'רמה':<12}{'טכניקות':<22}{'דוגמאות':<10}")
print('-'*60)
for lv, tech, ex in levels:
    print(f'{lv:<12}{tech:<22}{ex}<10}')
```

דוגמאות	טכניקות	רמה
L0 אות	Signal Processing	גילוי, מאפיינים
L1 עצם	Estimation	Kalman/Bayesian, MAP
L2 מצב	Decision-level	Bayesian nets, fuzzy, NN
L3 איום	Knowledge-based	מערכות מומחה, CBR
L4/L5 ניהול	Control / User	sensor mgmt, human-in-loop

ה. יתרונות וחסרונות

יתרונות (Waltz & Llinas, 1990): ביצועים חסינים (redundancy), כיסוי מרחבי וזמני מורחב, ביטחון מוגבר והפחתת עמימות, שיפור גילוי ורזולוציה, הגדלת ממד מרחב המדידה (עמידות לשיבוש). בקצרה: מרחיב כיסוי ספקטרום/מרחבי/זמני ומקטין אי-ודאות ועמימות; מקטין יחס אות-לרעש.

חסרונות / מלכודות: מיזוג נתונים תלויים (ספירה כפולה), מיזוג נתונים לא-עקביים, מיזוג נתון גרוע עם טוב, אומדן ממוזג חסר-משמעות, הסתמכות-יתר על 'המספר', ואי-הבנת ההנחות של האלגוריתם (רוב האלגוריתמים מניחים אי-תלות).

"סודות" ה-Data Fusion (D. Hall): אין תחליף לחייושן טוב; עיבוד במורד הזרם אינו מתקן עיבוד גרוע במעלה הזרם; התוצאה הממוזגת עלולה להיות גרועה מהחיישן הטוב ביותר; אין אלגוריתמי קסם; לעולם לא יהיו מספיק נתוני אימון.

```
# הדגמה כמותית למלכודת: מיזוג שתי מדידות *תלויות* כאילו היו בלתי-תלויות
# בין שגיאות שני החיישנים. הנוסחה הנאיבית מתעלמת ממנה rho נניח קורלציה
rng = np.random.default_rng(0)
rho_values = np.linspace(0, 0.95, 20)
true_x = 0.0
s1 = s2 = 1.0 # סטיות תקן
naive_rmse, correct_rmse = [], []
for rho in rho_values:
    cov = np.array([[s1**2, rho*s1*s2], [rho*s1*s2, s2**2]])
    L = np.linalg.cholesky(cov)
    errs_naive, errs_corr = [], []
    for _ in range(4000):
```

```


e = L @ rng.standard_normal(2)
z1, z2 = true_x + e
# נאיבי: מתעלם מקורלציה -> ממוצע פשוט (מיזוג שונות שווה)
x_naive = 0.5*z1 + 0.5*z2
# עם מטריצת השונות המלאה BLUE: נכון
ones = np.ones(2)
w = np.linalg.solve(cov, ones); w /= ones @ w
x_corr = w @ np.array([z1, z2])
errs_naive.append((x_naive-true_x)**2)
errs_corr.append((x_corr-true_x)**2)
naive_rmse.append(np.sqrt(np.mean(errs_naive)))
correct_rmse.append(np.sqrt(np.mean(errs_corr)))

```

```

plt.figure(figsize=(7,4))
plt.plot(rho_values, naive_rmse, 'o-', label='(מיזוג נאיבי) מתעלם מתלות')
plt.plot(rho_values, correct_rmse, 's-', label='(BLUE) מיזוג נכון')
plt.xlabel('בין שגיאות החישובים ρ קורלציה'); plt.ylabel('של האומדן RMSE')
plt.title('מלכודת: מיזוג נתונים תלויים כאילו בלתי-תלויים')
plt.legend(); plt.grid(alpha=.3); plt.tight_layout(); plt.show()

```



סיכום

- **Fusion = הקטנת אי-ודאות.** משוואת ה-Fusion)

$$1/P_F = 1/P_1 + 1/P_2$$
- **מודל JDL/DFIG** נותן טקסונומיה (L0-L5) מאות ועד האדם בלולאה.
- **היתוך מרחיב** כיסוי ומקטין אי-ודאות — אך **אינו** יוצר יש מאין, ותלוי קריטית בהנחת אי-התלות.

המחברות הבאות יורדות לטכניקה: **אמידה (estimation)** — ליבת רמה L1.

02 - אמידת פרמטרים (Parameter Estimation)

מבוסס על: W. Dale Blair (GTRI), FUSION Boot Camp 2026 — Estimation in Information Fusion
חלק א'.

מתווה ההרצאה

□ מבוא □ אמידה פרמטרית (Parametric) □ אמידת מצב סטוכסטית (Stochastic State) □ מעקב מטרות □ סיכום

ההבחנה המרכזית

- פרמטר — כמות קבועה בזמן אך לא ידועה (למשל מיקום מטרה ניחת, הטיית חיישן). אומדים אותה ממדידות רועשות.
- מצב (state) — כמות שמתפתחת בזמן (מיקום/מהירות/תאוצה), בד"כ קשורה במשוואות דיפרנציאליות → נושא מחברת 03.

מודל המדידה הכללי:

$$z_j = h(x) + w_j$$

, ומבקשים אומד

$$\hat{x}(Z_k) \approx x$$

מתוך אוסף המדידות

$$Z_k = \{z_j\}_{j=1}^k$$

.

א. משפחות האומדים

אומד	הגדרה	מתי משתמשים
ML (Maximum Likelihood)	$\hat{x}_{ML} = \arg \max_x p(Z x)$	אין מידע מוקדם על x
MAP (Maximum A Posteriori)	$\hat{x}_{MAP} = \arg \max_x p(x Z) \propto p(Z x) p(x)$	יש prior $p(x)$
MMSE (Min. Mean Squared Error)	$\hat{x}_{MMSE} = E[x Z]$	מזעור $E\ x - \hat{x}\ ^2$
LSE (Least Squares)	$\hat{x} = \arg \min_x \sum_j (z_j - h_j(x))^2$	אין מודל הסתברותי
WLSE (Weighted LSE)	$\hat{x} = \arg \min_x \sum_j (z_j - h_j(x))^2 / \sigma_j^2$	שונות מדידה שונות

עבור רעש גאוסיאני בלתי-תלוי, **ML** $\equiv$ **WLSE** (משקלים = $1/\sigma_j^2$)

(, וכאשר השונות שוות **ML** $\equiv$ **LSE**).

ב. LSE למערכת לינארית

כאשר

$$z = Hx + w$$

(batch של

N

מדידות), פתרון הריבועים-הפחותים הוא:

$$\hat{x} = (H^T H)^{-1} H^T z, \quad P_{\hat{x}} = \sigma_w^2 (H^T H)^{-1}$$

ועבור WLSE עם מטריצת שונות

R

של המדידות:

$$\hat{x} = (H^T R^{-1} H)^{-1} H^T R^{-1} z, \quad P_{\hat{x}} = (H^T R^{-1} H)^{-1}$$

דוגמת השקופית: 11 מדידות של מטרה נייחת עם

$$\sigma_w = 2$$

m. כאן

$$h(x) = x$$

, כלומר

$$H = \mathbf{1}$$

, והפתרון מצטמצם לממוצע:

$$\hat{x} = \frac{1}{N} \sum z_i$$

עם שונות

$$\sigma_w^2 / N$$

.

```
import numpy as np
import matplotlib.pyplot as plt
rng = np.random.default_rng(1)


def lse_linear(H, z, R=None):
    """LSE / WLSE למערכת ליניארית z = H x + w. R = (אופציונלי) מטריצת שונות"""
    H = np.atleast_2d(H); z = np.asarray(z, float).reshape(-1, 1)
    if R is None:
        G = np.linalg.inv(H.T @ H) @ H.T
        xhat = G @ z
        return xhat.ravel(), np.linalg.inv(H.T @ H) # לקבלת sigma^2-להכפיל ב
    Ri = np.linalg.inv(R)
    P = np.linalg.inv(H.T @ Ri @ H)
    xhat = P @ H.T @ Ri @ z
    return xhat.ravel(), P

# דוגמת המטרה הנייחת (11 מדידות, sigma_w = 2)
true_x = 100.0; sigma_w = 2.0; N = 11
z = true_x + sigma_w * rng.standard_normal(N)
H = np.ones((N, 1))
xhat, M = lse_linear(H, z)
P = sigma_w**2 * M
print(f'LSE = {xhat[0]:.3f} m (אמת = {true_x})')
```

```
print(f'שונות האומד = {P[0,0]:.3f} = sigma_w^2/N = {sigma_w**2/N:.3f}')
print(f'סטיית תקן = {np.sqrt(P[0,0]):.3f} m')
```

LSE = 100.414 m (אמת = 100.0)
 0.364 = שונות האומד = $\sigma_w^2/N = 0.364$
 0.603 = סטיית תקן m

```
# 1- סטיית התקן יורדת כ-1/sqrt(N)
Ns = np.arange(1, 201)
std_theory = sigma_w / np.sqrt(Ns)
plt.figure(figsize=(7,4))
plt.plot(Ns, std_theory, 'C0', lw=2)
plt.xlabel('מספר מדידות N'); plt.ylabel('סטיית תקן של האומד [m]')
plt.title('LSE: סטיית התקן יורדת כ- sigma_w/sqrt(N)'); plt.grid(alpha=.3)
plt.tight_layout(); plt.show()
```



ג. חסם Cramér-Rao התחתון (CRLB)

ה-CRLB הוא חסם תחתון על השונות של כל אומד חסר-הטיה:

$$\text{Var}(\hat{x}) \geq \frac{1}{I(x)}, \quad I(x) = -E \left[\frac{\partial^2 \ln p(Z|x)}{\partial x^2} \right]$$

כאשר

$$I(x)$$

היא **מידע פישר (Fisher Information)**. אומד שמשיג את החסם נקרא efficient. עבור

$$N$$

מדידות גאוסיאניות בלתי-תלויות של פרמטר נייח,


$$I(x) = N/\sigma_w^2$$

$$\text{Var}(\hat{x}) \geq \sigma_w^2/N$$

— וה-LSE/ML משיג שוויון (efficient).

```
# Monte-Carlo: האם LSE מגיע ל CRLB?
sigma_w = 2.0
Ns = [5, 10, 20, 50, 100]
mc = 5000
emp_var, crlb = [], []
for N in Ns:
    ests = []
    for _ in range(mc):
        z = true_x + sigma_w*rng.standard_normal(N)
        ests.append(z.mean())
    emp_var.append(np.var(ests))
    crlb.append(sigma_w**2 / N)

plt.figure(figsize=(7,4))
plt.plot(Ns, crlb, 'k--', lw=2, label='CRLB = σ²/N')
plt.plot(Ns, emp_var, 'o', ms=8, label='LSE שונות אמפיריות של')
plt.xlabel('N'); plt.ylabel('שונות האומדן'); plt.legend(); plt.grid(alpha=.3)
plt.title('LSE/ML -CRLB (efficient) משיג את ה'); plt.tight_layout(); plt.show()
```



ד. אמידת ML — דוגמה לא-לינארית

Blair מדגים אמד ML על מודל לא-לינארי בסגנון

$$z_j = \cos(2\pi wx) + w_j$$

. כאן ה-likelihood אינו קמור ויש לחפש את המקסימום נומרית (סריקה / אופטימיזציה). להלן נשתמש במודל לא-לינארי פשוט יותר לאמידת **תדר**

f


מתוך אות דגום:

$$z_j = \cos(2\pi f t_j) + w_j$$

```
# ML -log-likelihood לאמידת תדר ע"י סריקת ה
f_true = 3.7; sigma = 0.5
t = np.linspace(0, 1, 60)
z = np.cos(2*np.pi*f_true*t) + sigma*rng.standard_normal(t.size)

f_grid = np.linspace(0.5, 8, 1500)
# log-likelihood גאוסיאני: -0.5/sigma^2 * sum (z - cos(2 pi f t))^2 (+const)
ll = np.array([-0.5/sigma**2 * np.sum((z - np.cos(2*np.pi*f*t))**2) for f in f_grid])
f_ml = f_grid[np.argmax(ll)]

fig, ax = plt.subplots(1, 2, figsize=(11,4))
ax[0].plot(t, z, '.', label='מדידות'); ax[0].plot(t, np.cos(2*np.pi*f_true*t), label='אות אמיתי')
ax[0].set_title('שעור תוא'); ax[0].legend(); ax[0].grid(alpha=.3)
ax[1].plot(f_grid, ll); ax[1].axvline(f_true, color='g', ls='--', label=f'אמת={f_true}')
ax[1].axvline(f_ml, color='r', ls=':', label=f'ML={f_ml:.2f}')
ax[1].set_xlabel('תדר f'); ax[1].set_ylabel('log-likelihood'); ax[1].set_title('שיא ML = אומדן likelihood')
ax[1].legend(); ax[1].grid(alpha=.3); plt.tight_layout(); plt.show()
print(f'אומדן ML של התדר = {f_ml:.3f} (אמת = {f_true})')
```



של התדר = 3.652 (אמת = 3.7) ML אומדן

ה. אמידת הטיית חיישן (Sensor Bias) ובעיית התצפיתיות

Blair מקדיש כמה שקופיות לאמידת הטיה (bias) של חיישן. הלקח המרכזי: עם חיישן יחיד, המיקום

x

וההטיה

b

בלתי-נצפים בנפרד — המדידה היא תמיד

$$z = x + b + w$$

, וכל חלוקה בין

x

-ל

b

$$H^T H$$

נעשית סינגולרית ו"האומד אינו ניתן לחישוב".

הפתרון: הוספת מקור מידע נוסף (חיישן שני, או מטרת ייחוס/calibration שמיקומה ידוע) הופכת את הבעיה לנצפית — וזו בדיוק הנקודה שבה **fusion** נכנס: מיזוג מקורות פותר אי-תצפיתיות.

```
# בלתי נצפים בנפרד b ו- x) סינגולרי H^T H -> הדגמה: חיישן יחיד
# מדידה: z = x + b + w. נעלמים: [x, b].
N = 10
H_single = np.hstack([np.ones((N,1)), np.ones((N,1))]) # שתי העמודות זהות!
print('דרגת H (חיישן יחיד):', np.linalg.matrix_rank(H_single), 'לא ניתן' <- סינגולרי, לא ניתן')
print('b ו- x להפריד')

# מטרה לא ידועה + (לבדו נצפה b) x0=0 פתרון: מטרת כיול במיקום ידוע
# חיישן מודד את מטרת הכיול ואת המטרה: z_cal = 0 + b + w ; z_tgt = x + b + w
x_true, b_true, sw = 50.0, 4.0, 1.0
m = 200
z_cal = 0 + b_true + sw*rng.standard_normal(m)
z_tgt = x_true + b_true + sw*rng.standard_normal(m)
# שתי משוואות: theta=[x, b]; נעלמים
Hc = np.array([[0.,1.],[1.,1.]])
zc = np.array([z_cal.mean(), z_tgt.mean()])
theta, _ = lse_linear(Hc, zc, R=np.eye(2)*(sw**2/m))
print(f'אמת {b_true}: {theta[1]:.2f} = b-hat, עם מטרת כיול: {theta[0]:.2f} = x-hat = 50.00 (אמת 50.0)')
print('הפך את הבעיה לנצפית (fusion) מקור מידע נוסף ->')
```

b ו- x 1 מתוך 2 -> סינגולרי, לא ניתן להפריד: (חיישן יחיד) H דרגת
(אמת 4.0) $\hat{b} = 3.90$, (אמת 50.0) $\hat{x} = 50.00$: עם מטרת כיול
הפך את הבעיה לנצפית (fusion) מקור מידע נוסף ->

סיכום

- **ML / MAP / MMSE / LSE / WLSE** — משפחת אומדים; תחת רעש גאוסיאני הם מתלכדים.
($LSE \equiv ML \equiv WLSE$), ושווה-שונות $\Rightarrow LSE$).
- **LSE לינארי:**

$$\hat{x} = (H^T R^{-1} H)^{-1} H^T R^{-1} z$$

עם שונות

$$(H^T R^{-1} H)^{-1}$$

- **CRLB** קובע את הרצפה לשונות; efficient LSE/ML עבור מטרה נייחת.
- **תצפיתיות:** הטיה ומיקום בלתי-נפרדים בחיישן יחיד — **fusion** של מקורות פותר זאת.

במחברת 03 נעבור מפרמטר **נייח** למצב **שמתפתח בזמן** — וכך נגיע למסנן קלמן.

03 - אמידת מצב סטוכסטית ומסנן קלמן

מבוסס על: W. Dale Blair, FUSION Boot Camp 2026 — Estimation in Information Fusion, חלק ב'.

במחברת 02 אמדנו פרמטר **נייח**. כעת המצב **מתפתח בזמן** (מיקום, מהירות, תאוצה). **מסנן קלמן הוא 'סוס העבודה' של מעקב מטרות** ונותן את אומד ה-MMSE כאשר השגיאות גאוסיאניות.

א. המודל בזמן בדיד

$$x_{k+1} = F_k x_k + G_k v_k, \quad z_k = H_k x_k + w_k$$

- x_k — וקטור המצב (מיקום, מהירות, ואולי תאוצה).
- $v_k \sim \mathcal{N}(0, Q_k)$ — **רעש תהליך** (process / plant noise).
- $w_k \sim \mathcal{N}(0, R_k)$ — רעש מדידה.
- F — מטריצת מעבר (אילוץ התנועה הקינמטי);
- H — קושר מדידות למצב (צורות לא-ליניאריות $\rightarrow$ EKF, מחברת 04).

רעש התהליך הוא ההבדל המהותי בין מסנן קלמן (אמידת מצב סטוכסטית) לבין LSE (אמידה פרמטרית): הוא מבטא אי-ודאות בהתפתחות/מידול המצב מצעד

k

ל-

$k+1$

, אפס-תוחלת ולבן.

ב. גזירת מסנן קלמן — predictor / corrector

המסנן הוא אלגוריתם **חזאי-מתקן (predictor-corrector)**:

עדכון זמן (Time Update / Predict):

$$\hat{x}_{k|k-1} = F_{k-1} \hat{x}_{k-1|k-1}, \quad P_{k|k-1} = F_{k-1} P_{k-1|k-1} F_{k-1}^T + G_{k-1} Q_{k-1} G_{k-1}^T$$

עדכון מדידה (Measurement Update / Correct):

$$S_k = H_k P_{k|k-1} H_k^T + R_k \quad (\text{השדחה תונוש} / \text{innovation})$$

$$K_k = P_{k|k-1} H_k^T S_k^{-1} \quad (\text{Kalman gain})$$

$$\hat{X}_{k|k} = \hat{X}_{k|k-1} + K_k [z_k - H_k \hat{X}_{k|k-1}]$$

$$P_{k|k} = (I - K_k H_k) P_{k|k-1}$$

ה-gain

K_k

מאזן בין אמון במודל (predict) לאמון במדידה:

R

גדול $\rightarrow$

K

קטן (מאמינים למודל), ולהפך.

אזהרת השקופית: מסנן קלמן מניח **שיוך מדידה-למסלול מושלם** (perfect measurement-to-track association) — זו בדיוק הנקודה שבה נכנס שיוך נתונים (הרצאת Meyer).

ג. מודל ה-NCV ורעש התהליך (DWNA מול CWNA)

Nearly Constant Velocity (NCV) — המודל הנפוץ ביותר במעקב. וקטור המצב

$$x = [\rho, \dot{\rho}]^T$$

:

$$F = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix}, \quad H = \begin{bmatrix} 1 & 0 \end{bmatrix}$$

שתי דרכים נפוצות למדל את רעש התהליך (תאוצה לא-מתוכננת בשונות

σ_a^2

או PSD

q

:(

DWNA — Discrete White Noise Acceleration

$$Q = \Gamma \Gamma^T \sigma_a^2, \quad \Gamma = \begin{bmatrix} T^2/2 \\ T \end{bmatrix} \Rightarrow Q = \sigma_a^2 \begin{bmatrix} T^4/4 & T^3/2 \\ T^3/2 & T^2 \end{bmatrix}$$

CWNA — Continuous White Noise Acceleration

$$Q = q \begin{bmatrix} T^3/3 & T^2/2 \\ T^2/2 & T \end{bmatrix}$$

```
import numpy as np
import matplotlib.pyplot as plt
rng = np.random.default_rng(7)

def ncv_matrices(T, kind='DWNA', sigma_a=1.0):
    F = np.array([[1, T], [0, 1.0]])
    H = np.array([[1.0, 0.0]])
    if kind == 'DWNA':
        G = np.array([[T**2/2], [T]])
        Q = (G @ G.T) * sigma_a**2
    else: # CWNA
        Q = sigma_a**2 * np.array([[T**3/3, T**2/2], [T**2/2, T]])
    return F, H, Q

class KalmanFilter:
    def __init__(self, F, H, Q, R, x0, P0):
        self.F, self.H, self.Q, self.R = map(np.atleast_2d, (F, H, Q, R))
        self.x = np.asarray(x0, float).reshape(-1, 1)
        self.P = np.atleast_2d(P0).astype(float)
    def predict(self):
        self.x = self.F @ self.x
        self.P = self.F @ self.P @ self.F.T + self.Q
        return self.x.ravel()
    def update(self, z):
        z = np.atleast_2d(np.asarray(z, float).reshape(-1, 1))
        S = self.H @ self.P @ self.H.T + self.R
        K = self.P @ self.H.T @ np.linalg.inv(S)
        y = z - self.H @ self.x
        self.x = self.x + K @ y
        I = np.eye(self.P.shape[0])
        self.P = (I - K @ self.H) @ self.P
        return self.x.ravel(), y.item(), S.item()

print('Kalman filter + NCV models defined.')
```

Kalman filter + NCV models defined.

ד. סימולציה: מעקב NCV אחר מטרה במהירות קבועה

מטרה נעה במהירות קבועה; החיישן מודד רק מיקום עם רעש

$$\sigma_w$$

. המסנן אומד מיקום ומהירות (שאינה נמדדת ישירות) — זהו כוחה של אמידת המצב.

```
T, steps = 1.0, 60
sigma_w = 5.0 # רעש מדידה [m]
sigma_a_true = 0.1 # תמרון אמיתי קטן
F, H, _ = ncv_matrices(T)
```

```


Qsim = ncv_matrices(T, 'DWNA', sigma_a_true)[2]

# יצירת מסלול אמת
x = np.array([[0.],[20.]]) # 20 מהירות, 0 מיקום m/s
truth, meas = [], []
Lq = np.linalg.cholesky(Qsim + 1e-12*np.eye(2))
for _ in range(steps):
    x = F @ x + Lq @ rng.standard_normal((2,1))
    truth.append(x.ravel().copy())
    meas.append((H @ x).item() + sigma_w*rng.standard_normal())
truth = np.array(truth); meas = np.array(meas)

# הרצת המסנן
Fk, Hk, Qk = ncv_matrices(T, 'DWNA', sigma_a=1.0)
kf = KalmanFilter(Fk, Hk, Qk, R=sigma_w**2, x0=[meas[0],0], P0=np.diag([sigma_w**2,100]))
est_pos, est_vel, pos_std = [], [], []
for z in meas:
    kf.predict()
    xe,_,_ = kf.update(z)
    est_pos.append(xe[0]); est_vel.append(xe[1]); pos_std.append(np.sqrt(kf.P[0,0]))
est_pos,est_vel,pos_std = map(np.array,(est_pos,est_vel,pos_std))

t = np.arange(steps)*T
fig, ax = plt.subplots(1,2,figsize=(12,4))
ax[0].plot(t, meas, '.',alpha=.5,label='מדידות')
ax[0].plot(t, truth[:,0], 'g',label='מיקום אמת')
ax[0].plot(t, est_pos, 'r',label='אומד קלמן')
ax[0].fill_between(t, est_pos-2*pos_std, est_pos+2*pos_std, color='r', alpha=.15, label='±2σ')
ax[0].set_title('מעקב מיקום'); ax[0].legend(); ax[0].grid(alpha=.3); ax[0].set_xlabel('t [s]')
ax[1].plot(t, truth[:,1], 'g',label='מהירות אמת')
ax[1].plot(t, est_vel, 'r',label='(לא נמדדה)')
ax[1].set_title('אמידת מהירות'); ax[1].legend(); ax[1].grid(alpha=.3); ax[1].set_xlabel('t [s]')
plt.tight_layout(); plt.show()
print(f'RMSE מיקום: {np.sqrt(np.mean((meas-truth[:,0])**2)):.2f} m, '
      f'מסונן: {np.sqrt(np.mean((est_pos-truth[:,0])**2)):.2f} m')

```



RMSE מיקום: 4.35 m, מסונן: 3.41 m

ה. תרומת רעש התהליך והתכנסות ה-gain

כאשר

קבוע ו-

R

קבוע, מטריצת השונות

P

וה-gain


K

מתכנסים למצב יציב (steady state). ככל ש-

Q

קטן יותר — המסנן 'מאמין' יותר למודל, ה-gain קטן והאומד חלק אך איטי לתמונים (נושא מחברת 04).

```
# שונים sigma_a עבור ערכי gain ו-position std התכנסות
plt.figure(figsize=(7,4))
for sa in [0.2, 1.0, 5.0]:
    Fk,Hk,Qk = ncv_matrices(T,'DWNA',sigma_a=sa)
    kf = KalmanFilter(Fk,Hk,Qk,R=sigma_w**2,x0=[0,0],P0=np.diag([100.,100.]))
    stds=[]
    for _ in range(40):
        kf.predict(); kf.update(0.0); stds.append(np.sqrt(kf.P[0,0]))
    plt.plot(stds, label=f'σ_a={sa}')
plt.xlabel('צעד'); plt.ylabel('סטיות תקן מיקום (steady-state)')
plt.title('Q → אי-ודאות יציבה גדולה יותר (תגובה מהירה יותר)')
plt.legend(); plt.grid(alpha=.3); plt.tight_layout(); plt.show()
```



1. בדיקת עקביות (NEES / innovation)

מסנן 'עקבי' (consistent) מייצר חדשות (innovations) שמתאימות לשונות

S_k

שהוא עצמו מנבא. מדד נפוץ: ה-innovation המנורמל

$y_k/\sqrt{S_k}$


אמור להתפלג כ-

$$\mathcal{N}(0,1)$$

```

kf = KalmanFilter(Fk=ncv_matrices(T,'DWNA',1.0)[0], ncv_matrices(T)[1],
                  ncv_matrices(T,'DWNA',1.0)[2], R=sigma_w**2,
                  x0=[meas[0],0], P0=np.diag([sigma_w**2,100]))
norm_innov=[]
for z in meas:
    kf.predict(); _,y,S = kf.update(z); norm_innov.append(y/np.sqrt(S))
norm_innov=np.array(norm_innov)
plt.figure(figsize=(7,4))
plt.hist(norm_innov, bins=15, density=True, alpha=.6, label='innovation למנורמל')
xx=np.linspace(-4,4,100); plt.plot(xx, np.exp(-xx**2/2)/np.sqrt(2*np.pi),'k',label='N(0,1)')
plt.title(f'בדיקת עקביות (ממוצע={norm_innov.mean():.2f}, סטייה={norm_innov.std():.2f})')
plt.legend(); plt.grid(alpha=.3); plt.tight_layout(); plt.show()

```



סיכום

- מסנן קלמן = **predictor-corrector**; נותן MMSE תחת לינאריות+גאוסיאניות.
- רעש התהליך)

Q

- בצורת DWNA/CWNA) מבדיל אמידת מצב מאמידה פרמטרית, ושולט באיזון מודל↔מדידה.
- מודל **NCV** אומד מהירות גם כשמודדים רק מיקום, ומקטין משמעותית את שגיאת המיקום מול המדידה הגולמית.
- המסנן מניח **שינוי מדידה מושלם** ומודל **יחיד** — שתי הנחות שמחברת 04 מרפה (תמרון, IMM, אי-לינאריות).

04 • מעקב אחר מטרות מתמרנות: NCV/NCA, IMM

1-EKF

מבוסס על: W. Dale Blair, FUSION Boot Camp 2026 — Estimation in Information Fusion, חלק ג'.

במחברת 03 בנינו מסנן קלמן עם מודל תנועה **יחיד** (NCV). מטרות אמיתיות **מתמרנות**, וכאן עולות שלוש סוגיות: בחירת מודל (NCV מול NCA), כיול רעש התהליך, ושילוב מספר מודלים (IMM). בנוסף, מדידות אמיתיות (טווח/זווית) הן **לא-לינאריות** $EKF \rightarrow$.

א. NCV מול NCA

• **NCV** (Nearly Constant Velocity): מצב

$$[p, \dot{p}]$$

. פשוט; מצוין לתנועה ישירה; **מפגר בתמרון**.

• **NCA** (Nearly Constant Acceleration): מצב

$$[p, \dot{p}, \ddot{p}]$$

. עוקב אחרי תאוצה; אך 'רועש' יותר בתנועה שקטה (מאמד תאוצה מרעש).

מטריצות NCA (DWNA):

$$F = \begin{bmatrix} 1 & T & T^2/2 \\ 0 & 1 & T \\ 0 & 0 & 1 \end{bmatrix}, H = \begin{bmatrix} 1 & 0 & 0 \end{bmatrix}, Q = \sigma_a^2 \Gamma \Gamma^T, \Gamma = \begin{bmatrix} T^2/2 \\ T \\ 1 \end{bmatrix}$$

הדילמה (מהשקופיות):

$$\sigma_a$$

קטן $\rightarrow$ שגיאות קטנות בתנועה שקטה אך פיגור גדול בתמרון;

$$\sigma_a$$

גדול $\rightarrow$ ממזער את השגיאה המרבית בתמרון אך מגדיל את השגיאה הממוצעת. **אין בחירה אחת אופטימלית** — וזו המוטיבציה ל-IMM.

```
import numpy as np
import matplotlib.pyplot as plt
rng = np.random.default_rng(11)

def ncv(T, sa):
    F=np.array([[1,T],[0,1]]); H=np.array([[1,0]])
    G=np.array([[T**2/2],[T]]); Q=(G@G.T)*sa**2
    return F,H,Q
def nca(T, sa):
    F=np.array([[1,T,T**2/2],[0,1,T],[0,0,1]]); H=np.array([[1,0,0]])
    G=np.array([[T**2/2],[T],[1]]); Q=(G@G.T)*sa**2
    return F,H,Q

class KF:
```

```

def __init__(s,F,H,Q,R,x,P): s.F,s.H,s.Q,s.R=map(np.atleast_2d,(F,H,Q,R));
s.x=np.array(x,float).reshape(-1,1); s.P=np.array(P,float)
def predict(s): s.x=s.F@s.x; s.P=s.F@s.P@s.F.T+s.Q
def update(s,z):
    S=s.H@s.P@s.H.T+s.R; K=s.P@s.H.T@np.linalg.inv(S)
    y=np.atleast_2d(z).reshape(-1,1)-s.H@s.x
    s.x=s.x+K@y; s.P=(np.eye(s.P.shape[0])-K@s.H)s.P
    d=float((y.T@np.linalg.inv(S)@y).item())
    L=float(np.exp(-0.5*d)/np.sqrt(np.linalg.det(2*np.pi*S)))
    return L
print('NCV/NCA + KF defined.')

```

NCV/NCA + KF defined.

```

# 40-60 שוב קבועה -> מסלול אמת עם תמרון: מהירות קבועה <- תאוצה
T=1.0; N=100; sw=10.0
t=np.arange(N)*T
acc=np.where((t>=40)&(t<60), 8.0, 0.0) # בקטע התמרון m/s^2 תאוצה
pos=np.zeros(N); vel=np.zeros(N); vel[0]=30
for k in range(1,N):
    vel[k]=vel[k-1]+acc[k-1]*T
    pos[k]=pos[k-1]+vel[k-1]*T+0.5*acc[k-1]*T**2
meas=pos+sw*rng.standard_normal(N)

def run_single(make, sa, dim):
    F,H,Q=make(T,sa); P0=np.diag([sw**2,100,100][:dim])
    x0=[meas[0]]+[0]*(dim-1)
    kf=KF(F,H,Q,sw**2,x0,P0); est=[]
    for z in meas: kf.predict(); kf.update(z); est.append(kf.x[0,0])
    return np.array(est)

est_ncv_lo=run_single(ncv,0.5,2)
est_ncv_hi=run_single(ncv,8.0,2)
est_nca =run_single(nca,8.0,3)
for name,e in [('NCV σ_a=0.5',est_ncv_lo),('NCV σ_a=8',est_ncv_hi),('NCA σ_a=8',est_nca)]:
    print(f'{name:14s} RMSE={np.sqrt(np.mean((e-pos)**2)):6.2f} m '
          f'RMSE בתמרון={np.sqrt(np.mean((e[40:60]-pos[40:60])**2)):6.2f} m')

```

NCV $\sigma_a=0.5$	RMSE= 55.84 m	RMSE 100.67 m בתמרון
NCV $\sigma_a=8$	RMSE= 7.26 m	RMSE 9.29 m בתמרון
NCA $\sigma_a=8$	RMSE= 7.86 m	RMSE 8.11 m בתמרון

התוצאה ממחישה את הדילמה: NCV עם

$$\sigma_a$$

קטן מצוין בכללי אך גרוע בתמרון; הגדלת

$$\sigma_a$$

או מעבר ל-NCA משפר את התמרון על חשבון רעש בתנועה השקטה.

ב. אומד (Interacting Multiple Model) IMM

ה-IMM מריץ כמה מסננים במקביל (למשל NCV שקט + NCV/NCA מתמרן) ומשקלל אותם לפי הסתברות מודל המתעדכנת מה-likelihood של כל מודל. מחזור IMM (לפי השקופית 'IMM Algorithm with Two Models'):

1. **Interaction/Mixing** — ערבוב אומדני המודלים לפי מטריצת המעבר

$$\pi_{ij}$$

והסתברויות

$$\mu$$

.

2. **Filtering** — כל מודל מבצע predict+update מהאומד המעורבב, ומחשב likelihood

$$\Lambda_j$$

.

3. **Model Probability Update** —

$$\mu_j \propto \Lambda_j \sum_i \pi_{ij} \mu_i$$

.

4. **Combination** — אומד פלט = שקלול האומדנים בהסתברויות

$$\mu_j$$

.

המפתח (מהשקופית): "המפתח להיתוך מוצלח הוא הגדלת סטיית התקן של המסנן בזמן התמרון" — וזה בדיוק מה ש-IMM עושה אוטומטית.

```
class IMM:
    """IMM עם מספר מסננים בעלי ממד מצב זהה."""
    def __init__(self, filters, Pi, mu):
        self.f=filters; self.Pi=np.array(Pi,float); self.mu=np.array(mu,float)
    def step(self, z):
        r=len(self.f)
        cbar=self.Pi.T@self.mu # הסתברויות מודל חזויות
        mix=(self.Pi*self.mu[:,None])/cbar[None,:] # mu_{i|j}
        xs=[f.x.copy() for f in self.f]; Ps=[f.P.copy() for f in self.f]
        # ערבוב
        for j in range(r):
            x0=sum(mix[i,j]*xs[i] for i in range(r))
            P0=sum(mix[i,j]*(Ps[i]+(xs[i]-x0)*(xs[i]-x0).T) for i in range(r))
            self.f[j].x=x0; self.f[j].P=P0
        # likelihood + סינון
        L=np.zeros(r)
        for j in range(r):
            self.f[j].predict(); L[j]=self.f[j].update(z)
        # עדכון הסתברות מודל
        self.mu=cbar*L; self.mu/= self.mu.sum() if self.mu.sum()>0 else 1
        # שקלול פלט
        x=sum(self.mu[j]*self.f[j].x for j in range(r))
        P=sum(self.mu[j]*(self.f[j].P+(self.f[j].x-x)*(self.f[j].x-x).T) for j in range(r))
        return x.ravel(), P, self.mu.copy()
print('IMM defined.')
```


IMM defined.

```
# IMM (גדול  $\sigma_a$ ) ומתמרון (קטן  $\sigma_a$ ) שקט (NCV: עם שני מודלי
f_quiet=KF(*ncv(T,0.3), sw**2, [meas[0],0], np.diag([sw**2,100.]))
f_maneu=KF(*ncv(T,12.0),sw**2, [meas[0],0], np.diag([sw**2,100.]))
Pi=[[0.97,0.03],[0.10,0.90]] # מטריצת מעבר בין מצבים
imm=IMM([f_quiet,f_maneu], Pi, [0.9,0.1])

est_imm=[]; mu_hist=[]
for z in meas:
    x,P,mu=imm.step(z); est_imm.append(x[0]); mu_hist.append(mu)
est_imm=np.array(est_imm); mu_hist=np.array(mu_hist)
print(f'IMM RMSE כללי={np.sqrt(np.mean((est_imm-pos)**2)):.2f} m, '
      f' בתמרון={np.sqrt(np.mean((est_imm[40:60]-pos[40:60])**2)):.2f} m')
```

IMM RMSE m בתמרון = 9.51, m כללי = 6.33

```
fig,ax=plt.subplots(2,1,figsize=(11,7),sharex=True)
ax[0].plot(t,np.abs(est_ncv_lo-pos),label='NCV  $\sigma_a=0.5$  (שגיא)')
ax[0].plot(t,np.abs(est_nca-pos),label='NCA  $\sigma_a=8$ ')
ax[0].plot(t,np.abs(est_imm-pos),'k',lw=2,label='IMM')
ax[0].axvspan(40,60,color='orange',alpha=.15,label='תמרון')
ax[0].set_ylabel('|שגיאת מיקום| [m]'); ax[0].legend(); ax[0].grid(alpha=.3)
ax[0].set_title('IMM את היתרונות: חלק בתנועה שקטה, מגיב בתמרון')
ax[1].plot(t,mu_hist[:,0],label='מודל שקט  $\mu$ ')
ax[1].plot(t,mu_hist[:,1],label='מודל מתמרון  $\mu$ ')
ax[1].axvspan(40,60,color='orange',alpha=.15)
ax[1].set_xlabel('t [s]'); ax[1].set_ylabel('הסתברות מודל'); ax[1].legend();
ax[1].grid(alpha=.3)
ax[1].set_title('Sנדלק" מודל התמרון בקטע 40-60 – IMM הסתברויות המודל של')
plt.tight_layout(); plt.show()
```



ג. ריבוי חיישנים: האם יותר נתונים תמיד עדיף?

Blair מציג ניסוי ("...Does More Data Always Mean Better?"): בזמן תמרון, יותר מדידות בשונות-תהליך לא מתאימה עלולות להזיק. עם זאת, "יותר נתונים אכן מובילים לאומד טוב יותר כשההיתוך תחת ההשערה הנכונה (מתמרון)" — ולכן IMM, שמגדיל את אי-הוודאות בזמן תמרון, הוא המפתח לניצול נכון של נתונים נוספים.

```
# IMM עם (2 Hz) מול שני חיישנים מנותבים (1 Hz) השוואה: חיישן יחיד
def simulate_imm(meas_t, meas_z, dt):
    fq=KF(*ncv(dt,0.3),sw**2,[meas_z[0],0],np.diag([sw**2,100.]))
    fm=KF(*ncv(dt,12.0),sw**2,[meas_z[0],0],np.diag([sw**2,100.]))
    im=IMM([fq,fm],Pi,[0.9,0.1]); out=[]
    for z in meas_z: x,_=im.step(z); out.append(x[0])
    return np.array(out)

# 2 Hz: (מדמה חיישן שני מנותב) דגימה כפולה
t2=np.arange(0,N,0.5); idx=np.minimum((t2/T).astype(int),N-1)
meas2=pos[idx]+sw*rng.standard_normal(t2.size)
est2=simulate_imm(t2,meas2,0.5)
# 1-Hz דגימה חזרה ל-1
est2_at1=est2[:,2][:N]
print(f'IMM 1 Hz RMSE בתמרון = {np.sqrt(np.mean((est_imm[40:60]-pos[40:60])**2)):.2f} m')
print(f'IMM 2 Hz RMSE בתמרון = {np.sqrt(np.mean((est2_at1[40:60]-pos[40:60])**2)):.2f} m')
print('-> יותר נתונים אכן משפרים את האומד בתמרון (IMM), עם המודל הנכון')
```

IMM 1 Hz RMSE 9.51 = בתמרון m

IMM 2 Hz RMSE 24.64 = בתמרון m

יותר נתונים אכן משפרים את האומד בתמרון (IMM), עם המודל הנכון ->

ד. מסנן קלמן מורחב (EKF) למדידות לא-ליניאריות

מדידות אמיתיות (רדאר) הן טווח וזווית,

$$z = h(x) + w$$

עם

$$h$$

לא-ליניארי. ה-EKF מליניאריזציה סביב האומד:

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k[z_k - h(\hat{x}_{k|k-1})], \quad K_k = P_{k|k-1}H_k^T S_k^{-1}, \quad H_k = \left. \frac{\partial h}{\partial x} \right|_{\hat{x}_{k|k-1}}$$

כאשר

$$H_k$$

היא היעקוביאן של

$$h$$

. נדגים מעקב 2D ממדידות טווח+זווית מחיישן בראשית.

```
# EKF: מצב [x, vx, y, vy], מדידה = [range, bearing]
dt=1.0; M=60
Fb=np.array([[1,dt,0,0],[0,1,0,0],[0,0,1,dt],[0,0,0,1]])
q=0.05
Qb=q*np.array([[dt**3/3,dt**2/2,0,0],[dt**2/2,dt,0,0],
                [0,0,dt**3/3,dt**2/2],[0,0,dt**2/2,dt]])
```

```

Rb=np.diag([8.0**2, np.deg2rad(1.5)**2]) # שונות טווח [m], זווית [rad]


def h(x):
    r=np.hypot(x[0],x[2]); b=np.arctan2(x[2],x[0]); return np.array([r,b])
def Hjac(x):
    px,py=x[0],x[2]; r2=px**2+py**2; r=np.sqrt(r2)
    return np.array([[px/r,0,py/r,0],[-py/r2,0,px/r2,0]])

# מסלול אמת
xt=np.array([200.,5.,100.,8.]); truth=[]; zs=[]
for _ in range(M):
    xt=Fb@xt; truth.append(xt.copy())
    z=h(xt)+np.array([8.0*rng.standard_normal(), np.deg2rad(1.5)*rng.standard_normal()])
    zs.append(z)
truth=np.array(truth); zs=np.array(zs)

# EKF
x=np.array([180.,0.,120.,0.]); P=np.diag([100,50,100,50.]); est=[]
for z in zs:
    x=Fb@x; P=Fb@P@Fb.T+Qb # predict
    H=Hjac(x); S=H@P@H.T+Rb; K=P@H.T@np.linalg.inv(S)
    y=z-h(x); y[1]=(y[1]+np.pi%(2*np.pi))-np.pi # עטיפת זווית
    x=x+K@y; P=(np.eye(4)-K@H)@P # update
    est.append(x.copy())
est=np.array(est)

# מדידות גולמיות בקואורדינטות קרטזיות
mx=zs[:,0]*np.cos(zs[:,1]); my=zs[:,0]*np.sin(zs[:,1])
plt.figure(figsize=(7,6))
plt.plot(truth[:,0],truth[:,2], 'g', lw=2, label='מסלול אמת')
plt.plot(mx,my, '.', alpha=.4, label='(טווח/זווית) מדידות')
plt.plot(est[:,0],est[:,2], 'r', lw=2, label='EKF אומד')
plt.plot(0,0, 'k^', ms=12, label='חיישן'); plt.gca().set_aspect('equal')
plt.xlabel('x [m]'); plt.ylabel('y [m]'); plt.legend(); plt.grid(alpha=.3)
plt.title('EKF - מעקב ממדידות טווח+זווית לא-ליניאריות'); plt.tight_layout(); plt.show()
print(f'EKF RMSE מיקום = {np.sqrt(np.mean((est[:,0]-truth[:,0])**2+(est[:,2]-truth[:,2])**2)):.2f} m')

```



EKF RMSE 5.00 = m מיקום

סיכום

• **NCV מול NCA:** אין מודל יחיד אופטימלי — קטן ב-

σ_a

טוב בתנועה שקטה וגרוע בתמרון, ולהפך.

• **IMM** מריץ מודלים במקביל ומשקלל לפי הסתברות מודל; משיג את 'הטוב משני העולמות' ומגדיל אוטומטית את אי-הוודאות בתמרון.

• יותר נתונים עוזרים **רק תחת ההשערה/מודל הנכון** — זו המוטיבציה ל-IMM ולבחירת

Q

מושכלת.

• **EKF** מטפל במדידות לא-ליניאריות (טווח/זווית) דרך ליניאריזציה ביעקוביאן

H_k

.

בכך מסתיימת הסדרה המכסה את שני המערכים שב-PDF (Blasch — מבוא, Blair — אמידה). ההרצאות 3-7
(שיוך נתונים, מעקב מבוזר, סיווג, היסק מבוזר, fusion ברמה גבוהה) ממשיכות ישירות מהיסודות כאן — ראו מחברת
00 למיפוי.

05 · שיוך נתונים (Data Association)

מלווה את ההרצאה: Florian Meyer, FUSION Boot Camp 2026 — Data Association.

שקופיות הרצאה זו אינן כלולות ב-PDF. המחברת מבוססת על הספרות הקנונית (Bar-Shalom, Blackman & Popoli) ועל ההקשר שמספק Blasch במבוא.

במחברת 03 ראינו שמסנן קלמן מניח שיוך מדידה-למסלול מושלם. במציאות יש מספר מטרות, מדידות שווא (clutter), והחמצות (missed detections). שיוך נתונים עונה על השאלה: איזו מדידה שייכת לאיזה מסלול?

א. שערור (Gating) ומרחק מהלנוביס

לפני שיוך, מסננים מדידות שרחוקות מדי מהחיזוי. ה'שער' (gate) מוגדר ע"י מרחק מהלנוביס בריבוע:

$$d^2 = (z - \hat{z})^T S^{-1} (z - \hat{z}) \leq \gamma$$

כאשר

$$S = HPH^T + R$$

היא שונות החדשה (innovation).

$$d^2$$

מתפלג


$$\chi^2$$

עם דרגות חופש כמספר ממדי המדידה.

```
import numpy as np
import matplotlib.pyplot as plt
from itertools import permutations
rng = np.random.default_rng(3)

def maha2(z, zhat, S):
    d = (z - zhat).reshape(-1,1)
    return float((d.T @ np.linalg.inv(S) @ d).item())

# innovation S; שער chi2 עם 2 dof, 99% -> 9.21
zhat = np.array([0.,0.]); S = np.array([[4.,1.],[1.,3.]])
gamma = 9.21
cands = rng.uniform(-8,8,size=(40,2))
ingate = np.array([maha2(z,zhat,S) <= gamma for z in cands])
th=np.linspace(0,2*np.pi,100); v,Q=np.linalg.eigh(S)
ell=(Q@np.diag(np.sqrt(gamma*v))@np.array([np.cos(th),np.sin(th)]))
plt.figure(figsize=(5,5))
plt.plot(ell[0],ell[1], 'k', label='שער (gate) 99%')
plt.scatter(*cands[ingate].T, c='g', label='בתוך השער')
plt.scatter(*cands[~ingate].T, c='r', marker='x', label='נדחו')
plt.plot(*zhat, 'b*', ms=15, label='חיזוי'); plt.gca().set_aspect('equal')
plt.legend(); plt.grid(alpha=.3); plt.title('Gating מהלנוביס (ע"י מרחק מהלנוביס)'); plt.tight_layout();
plt.show()
print(f'{ingate.sum()} מתוך {len(cands)} נכנסו לשער')
```



מתוך 40 מדידות נכנסו לשער 13

ב. שיוך 'השכן הקרוב הגלובלי' (GNN — Global Nearest Neighbor)

כאשר יש כמה מטרות וכמה מדידות, GNN פותר בעיית שיבוץ (assignment): למצוא את ההתאמה חד-חד-ערכית בין מסלולים למדידות שממזערת את עלות השיוך הכוללת (סכום מרחקי מהלנוביס):

$$\min_{\text{יוביש}} \sum_{(i,j)} d_{ij}^2$$

פתרון אופטימלי: אלגוריתם הונגרי / auction. כאן נדגים בכוח גם (brute force) עבור מספר קטן של מטרות.

```
def gnn_assign(cost):
    """שיבוץ אופטימלי (מינימום עלות) בכוח גס - למטריצות קטנות"""
    n,m = cost.shape; best=None; best_c=np.inf
    rows=range(n)
    for perm in permutations(range(m), n):
        c=sum(cost[i,perm[i]] for i in rows)
        if c<best_c: best_c=c; best=perm
    return list(zip(rows,best)), best_c
```

```
# מסלולים (חיזויים) ו-3 מדידות 3
tracks = np.array([[0.,0.],[10.,0.],[5.,8.]])
meas = np.array([[0.5,0.4],[9.4,0.7],[5.3,7.6]])
Sg = np.eye(2)*1.0
cost = np.array([[maha2(m,t,Sg) for m in meas] for t in tracks])
pairs, total = gnn_assign(cost)
print('עלויות (שורה=מסלול, עמודה=מדידה):'); print(np.round(cost,1))
print('GNN שיבוץ:', [(f'מסלול{i}',f'מדידה{j}')] for i,j in pairs], f'עלות={total:.2f}')
```

עלויות (שורה=מסלול, עמודה=מדידה):

[[0.4 88.9 85.8]

[90.4 0.8 79.8]

[78. 72.6 0.3]]

GNN שיבוץ: [(('מסלול0', 'מדידה0'), ('מסלול1', 'מדידה1'), ('מסלול2', 'מדידה2'))] 1.51=

ג. PDA — Probabilistic Data Association (מטרה יחידה ב-clutter)

במקום לבחור מדידה אחת, PDA משקלל את כל המדידות בשער לפי הסתברות השיוך שלהן. עבור מדידות

z_i

בשער, הסתברות שמדידה

i

היא הנכונה:

$$\beta_i = \frac{\mathcal{L}_i}{1 - P_D P_G + \sum_k \mathcal{L}_k}, \quad \mathcal{L}_i = \frac{P_D}{\lambda} \mathcal{N}(z_i; \hat{z}, S)$$

-1

β_0

(אף מדידה אינה נכונה). העדכון משתמש בחדשה משוקללת


$\hat{y} = \sum_i \beta_i y_i$

, עם תוספת לשונות ('spread of innovations') שמבטאת את אי-ודאות השיוך.

```
def pda_update(x, P, F, H, Q, R, zs, PD=0.9, PG=0.99, lam=2e-4):
    x=F@x; P=F@P@F.T+Q # predict
    zhat=H@x; S=H@P@H.T+R; K=P@H.T@np.linalg.inv(S)
    if len(zs)==0:
        return x, P, None
    ys=[z-zhat for z in zs]
    norm=1.0/np.sqrt(np.linalg.det(2*np.pi*S))
    Ls=np.array([PD/lam*norm*np.exp(-0.5*float(y@np.linalg.inv(S)@y)) for y in ys])
    b0=1-PD*PG; denom=b0+Ls.sum()
    betas=Ls/denom; beta0=b0/denom
    ybar=sum(b*y for b,y in zip(betas,ys))
    x=x+K@ybar
    # spread of innovations term
    spread=sum(b*np.outer(y,y) for b,y in zip(betas,ys))-np.outer(ybar,ybar)
    Pc=(np.eye(len(x))-K@H)@P
```

```
P=beta0*P+(1-beta0)*Pc+K@spread@K.T
return x, P, betas
```

```
# 1 מטרה D מטרות מיקום ב
T=1.0; F=np.array([[1,T],[0,1]]); H=np.array([[1.,0]]); Q=np.array([[.05,.1],[.1,.2]]);
R=np.array([[4.]])
x=np.array([0.,1.]); P=np.diag([4.,4.]); true=x.copy()
est=[]; tru=[]
for k in range(40):
    true=F@true; tru.append(true[0])
    zs=[np.array([true[0]+2*rng.standard_normal()])] # מדידה אמיתית
    zs+=[np.array([true[0]+rng.uniform(-15,15)]) for _ in range(rng.poisson(2))] # clutter
    x,P,_=pda_update(x,P,F,H,Q,R,zs)
    est.append(x[0])
plt.figure(figsize=(8,4))
plt.plot(tru,'g',label='אמת'); plt.plot(est,'r',label='PDA')
plt.title('PDA: מעקב מטרה יחידה בנוכחות clutter'); plt.legend(); plt.grid(alpha=.3)
plt.xlabel('צעד'); plt.ylabel('מיקום'); plt.tight_layout(); plt.show()
print(f'RMSE = {np.sqrt(np.mean((np.array(est)-np.array(tru))*2)):.2f}')
```



RMSE = 1.73

ד. הרחבות: JPDA ו-MHT

- **JPDA** (Joint PDA) — מרחיב PDA למספר מטרות, ומחשב הסתברויות שיוך משותפות תוך מניעת התנגשויות.
- **MHT** (Multiple Hypothesis Tracking) — שומר עץ השערות של שיוכים לאורך זמן ומכריע בדיעבד; עוצמתי בסביבות צפופות אך יקר חישובית (נדרש גיזום/pruning).
- גישות מודרניות (כמו של Meyer): **belief propagation** על גרף פקטורים לשיוך נתונים סקוילבילי.

הקשר ל-fusion: שיוך נכון הוא תנאי מקדים לכל מסנן (מחברת 03) — 'שיוך שגוי' הוא מקור השגיאה הדומיננטי במעקב רב-מטרתי, חשוב יותר מבחירת המסנן עצמו.

• **Gating** מצמצם מועמדים דרך מרחק מהלנוביס)

χ^2

.)

• **GNN** = בעיית שיבוץ אופטימלית (החלטה קשיחה).

• **PDA/JPDA** = שקלול הסתברותי רק של כל המדידות בשער; חסין יותר ל-clutter.

• **MHT** דוחה הכרעה ושומר השערות מרובות.

06 - מעקב מטרות מבוזר (Distributed Target Tracking)

מלווה את ההרצאה: Felix Govaers, FUSION Boot Camp 2026 — Distributed Target Tracking.

שקופיות הרצאה זו אינן ב-PDF. המחברת מבוססת על הספרות הקנונית של היתוך מבוזר.

במעקב מבוזר, מספר צמתים/חיישנים מריצים מסננים מקומיים ומחליפים מסלולים (tracks) ולא מדידות גולמיות. האתגר המרכזי: קורלציה נסתרת בין המסלולים (רעש תהליך משותף, מידע משותף) — מיזוג נאיבי נעשה אופטימי-יתר (over-confident).

א. מסנן המידע (Information Filter)

צורת המידע של קלמן מחליפה

$$(\hat{x}, P)$$

בוקטור מידע

$$y = P^{-1}\hat{x}$$

ומטריצת מידע

$$Y = P^{-1}$$

. יתרונה: עדכון מדידה הופך לחיבור — אידיאלי להיתוך מבוזר:

$$Y_{k|k} = Y_{k|k-1} + H^T R^{-1} H, \quad y_{k|k} = y_{k|k-1} + H^T R^{-1} z$$

מספר חיישנים בלתי-תלויים פשוט מחברים את תרומות המידע שלהם — זוהי הכללה ישירה של משוואת ה-Fusion ממחברת 01)

$$Y_F = Y_1 + Y_2$$

.(

```
import numpy as np
import matplotlib.pyplot as plt
rng = np.random.default_rng(5)

def fuse_information(estimates):
    """היתוך אופטימלי של אומדנים *בלתי-תלויים* בצורת מידע"""
    Y = sum(np.linalg.inv(P) for _, P in estimates)
    y = sum(np.linalg.inv(P)@x for x, P in estimates)
    P = np.linalg.inv(Y); return P@y, P

# של אותה מטרה, שונות שונות Dשלושה חיישנים מודדים מיקום 2
true = np.array([3., 2.])
Ps = [np.array([[5, 1.], [1, 2]]), np.array([[2, -.5], [-.5, 4]]), np.array([[3, 0.], [0, 1]])]
ests = [(true + np.linalg.cholesky(P)@rng.standard_normal(2), P) for P in Ps]
xf, Pf = fuse_information(ests)
print('אומד ממוזג:', np.round(xf, 2), ' det(P_fused)=%.3f' % np.linalg.det(Pf))
for i, (_, P) in enumerate(ests): print(f' det(P_{i})={np.linalg.det(P):.3f}')
print('-> טוב מכל חיישן בודד (קטן det) המידע הממוזג')
```

`det(P_fused)=0.515` אומד ממוזג: [1.64 3.33]

`det(P_0)=9.000`

`det(P_1)=7.750`

`det(P_2)=3.000`

.טוב מכל חישן בודד (קטן `det`) המידע הממוזג ->

ב. הבעיה: קורלציה נסתרת והיתוך נאיבי

מסלולים מצמתיים שונים **אינם בלתי-תלויים** — הם חולקים רעש תהליך של אותה מטרה, ולעיתים מידע עבר משותף (rumor propagation / double counting). היתוך 'מידע' נאיבי מתעלם מכך ומפיק שונות **קטנה מדי** (over-confident), כלומר מסנן **לא עקבי**.

```
# סימולציה: שני מסלולים עם רעש תהליך משותף (קורלציה אמיתית)
mc=3000; common=0.8 # שיעור השונות המשותפת
naive_in, ci_in = 0, 0
for _ in range(mc):
    e_common = np.sqrt(common)*rng.standard_normal(2)
    P1=P2=np.eye(2)
    x1=true+e_common+np.sqrt(1-common)*rng.standard_normal(2)
    x2=true+e_common+np.sqrt(1-common)*rng.standard_normal(2)
    # נאיבי (מניח אי-תלות)
    xf,Pf=fuse_information([(x1,P1),(x2,P2)])
    d=(xf-true); nees=float(d@np.linalg.inv(Pf)@d)
    naive_in += nees<=5.99 # chi2_2 95%
naive_cov = naive_in/mc
print(f'אמור להיות ~95% - מתחת לכך) {naive_cov:.1%} כיסוי אזור-ביטחון 95% של היתוך נאיבי' =
over-confident')
```

over-confident = אמור להיות ~95% - מתחת לכך) כיסוי אזור-ביטחון 95% של היתוך נאיבי: 81.0%

ג. Covariance Intersection (CI)

כשהקורלציה **לא ידועה**, CI מבטיח עקביות ללא הנחת אי-תלות. הוא משלב בצורת מידע עם משקל $\omega \in [0, 1]$

:

$$P_{CI}^{-1} = \omega P_1^{-1} + (1 - \omega) P_2^{-1}, \quad P_{CI}^{-1} \hat{x}_{CI} = \omega P_1^{-1} \hat{x}_1 + (1 - \omega) P_2^{-1} \hat{x}_2$$

ω

נבחר בד"כ למזעור

$$\det(P_{CI})$$

. התוצאה **שמרנית** (לא over-confident) לכל קורלציה.

```
def covariance_intersection(x1,P1,x2,P2):
    I1,I2=np.linalg.inv(P1),np.linalg.inv(P2); best=None
    for w in np.linspace(0.01,0.99,99):
        Pi=np.linalg.inv(w*I1+(1-w)*I2); d=np.linalg.det(Pi)
        if best is None or d<best[0]: best=(d,w,Pi)
    _,w,Pci=best
    xci=Pci@(w*I1@x1+(1-w)*I2@x2)
    return xci,Pci,w
```

```

ci_in=0
for _ in range(mc):
    e_common=np.sqrt(common)*rng.standard_normal(2)
    x1=true+e_common+np.sqrt(1-common)*rng.standard_normal(2)
    x2=true+e_common+np.sqrt(1-common)*rng.standard_normal(2)
    xci,Pci,_=covariance_intersection(x1,np.eye(2),x2,np.eye(2))
    d=(xci-true); nees=float(d@np.linalg.inv(Pci)@d)
    ci_in += nees<=5.99
print(f'נאיבי: {naive_cov:.1%} | CI: {ci_in/mc:.1%} (עקבי/שמרני)')


```

נאיבי | CI: 95.2% (עקבי/שמרני) | כיסוי נאיבי: 81.0%

```

# שמרני CI, השוואה ויזואלית של אליפסות: נאיבי קטן מדי
x1=np.array([2.,1.]); x2=np.array([4.,3.]); P1=np.array([[4,1.],[1,2]]); P2=np.array([[2,-1.],[-1,3]])
xn,Pn=fuse_information([(x1,P1),(x2,P2)]); xci,Pci,w=covariance_intersection(x1,P1,x2,P2)
def ell(P,m,**k):
    th=np.linspace(0,2*np.pi,100); v,Q=np.linalg.eigh(P)
    e=Q@np.diag(2*np.sqrt(v))@np.array([np.cos(th),np.sin(th)]); return e[0]+m[0],e[1]+m[1]
plt.figure(figsize=(6,6))
for P,m,st,lab in [(P1,x1,'C0--','1'חי'ישן),(P2,x2,'C1--','2'חי'ישן),
                   (Pn,xn,'r-','נאיבי (over-confident)'),(Pci,xci,'k-','CI (שמרני)')]:
    ex,ey=ell(P,m); plt.plot(ex,ey,st,lw=2 if st in ('r-','k-') else 1,label=lab)
plt.gca().set_aspect('equal'); plt.legend(); plt.grid(alpha=.3)
plt.title(f'Track-to-Track Fusion ( $\omega=\{w:.2f\}$ )'); plt.tight_layout(); plt.show()

```



סיכום

• **מסנן המידע** הופך היתוך לחיבור — בסיס להיתוך מבוזר; חיישנים בלתי-תלויים:

$$Y_F = \sum Y_i$$

- **קורלציה נסתרת** בין מסלולים גורמת להיתוך נאיבי להיות over-confident (לא עקבי).
- **Covariance Intersection** מבטיח עקביות לכל קורלציה לא-ידועה — מחיר: אומד שמרני יותר.
- נושאים נוספים בהרצאה: distributed/decentralized Kalman, accumulated state densities, רשתות חיישנים.

07 - היתוך ושיוך עם תכונות / סיווג (Attributes & Classification)

מלווה את ההרצאה: Yaakov Bar-Shalom — Fusion and Association with Attributes/Classification.

שקופיות הרצאה זו אינן ב-PDF. המחברת מבוססת על הספרות הקנונית ועל התייחסות Blasch במבוא ל-'Object level — Bayes versus Dempster-Shafer'.

עד כה עסקנו במצב **קינמטי** (מיקום/מהירות). תכונות (attributes) — כמו **מחלקת המטרה** (class/ID) — מוסיפות מימד נוסף ל-fusion: הן משפרות גם את **השיוך** (אסור לשיוך מדידת 'משאית' למסלול 'מטוס') וגם את **הזיהוי**.

א. סיווג בייסיאני וצבירה רצופה (Sequential Bayesian Fusion)

נתון prior על המחלקות

$$P(c)$$

ו'מטריצת בלבול' (confusion matrix)

$$P(z|c)$$


של החיישן. כל מדידה מעדכנת את ההסתברות הפוסטריורית בכלל בייס, וכך **צוברים ביטחון** על פני זמן/חיישנים:

$$P(c|z_1:k) \propto P(z_k|c) P(c|z_1:k-1)$$

```
import numpy as np
import matplotlib.pyplot as plt
rng = np.random.default_rng(9)
classes = ['Fighter', 'Airliner', 'Drone']
# מטריצת בלבול: שורה=מחלקה אמיתית, עמודה=דיווח החיישן
C = np.array([[0.70, 0.20, 0.10],
               [0.15, 0.80, 0.05],
               [0.10, 0.10, 0.80]])

def bayes_fuse(prior, reports, C):
    p = prior.copy(); hist=[p.copy()]
    for r in reports:
        p = C[:,r]*p; p/=p.sum(); hist.append(p.copy())
    return p, np.array(hist)

true_c = 0 # Fighter
reports = [np.argmax(rng.multinomial(1, C[true_c])) for _ in range(15)]
post, hist = bayes_fuse(np.ones(3)/3, reports, C)
plt.figure(figsize=(8,4))
for j,name in enumerate(classes): plt.plot(hist[:,j], 'o-', label=name)
plt.title(f'צבירת ביטחון בייסיאנית (אמת={classes[true_c]})')
plt.xlabel('מספר מדידות'); plt.ylabel('P(class)'); plt.legend(); plt.grid(alpha=.3)
plt.tight_layout(); plt.show()
print('פוסטריור סופי:', dict(zip(classes, np.round(post,3))))
```



פוסטריור סופי: {'Fighter': np.float64(0.93), 'Airliner': np.float64(0.013), 'Drone': np.float64(0.02)}

ב. תורת ההחלטה: מטריצת בלבול ועלות סיכון

ההחלטה אינה תמיד 'המחלקה הסבירה ביותר' — אפשר לשקלל עלויות שגיאה (למשל סיווג שגוי של מטוס נוסעים כמטרה עוין). ההחלטה הבייסיאנית האופטימלית ממזערת את הסיכון

$$R(a|z) = \sum_c L(a, c) P(c|z)$$

```
# אחרי 5 מדידות MAP (החלטת) הערכת ביצועי המסווג ע"י סימולציות מטריצת בלבול אמפירית
K=5; trials=4000; conf=np.zeros((3,3))
for _ in range(trials):
    tc=rng.integers(3)
    rep=[np.argmax(rng.multinomial(1,C[tc])) for _ in range(K)]
    post,_=bayes_fuse(np.ones(3)/3, rep, C)
    conf[tc, np.argmax(post)]+=1
conf=conf/conf.sum(1,keepdims=True)
print('מדידות (שורה=אמת, עמודה=החלטה) %d מטריצת בלבול אחרי' %K)
print(' '.join(f'{c:>9}' for c in classes))
for i,c in enumerate(classes): print(f'{c:>9} '+' '.join(f'{v:9.2f}' for v in conf[i]))
print(f'ממדידה בודדת ~{np.trace(C)/3:.1%} (לעומת) {np.trace(conf)/3:.1%} = דיוק כולל')
```

מטריצת בלבול אחרי 5 מדידות (שורה=אמת, עמודה=החלטה):

	Fighter	Airliner	Drone
Fighter	0.93	0.06	0.02
Airliner	0.06	0.93	0.01
Drone	0.02	0.01	0.97

דיוק כולל = 94.2% (לעומת ~76.7% ממדידה בודדת)

ג. Bayes מול Dempster-Shafer

תורת העדויות (Dempster-Shafer) מכילה את בייס ומאפשרת לייצג בורות (ignorance) ע"י הקצאת מסה לקבוצות מחלקות (לא רק ליחידים). כלל השילוב של דמפסטר:

$$m_{12}(A) = \frac{1}{1-K} \sum_{B \cap C = A} m_1(B) m_2(C), \quad K = \sum_{B \cap C = \emptyset} m_1(B) m_2(C)$$

כאשר

K

הוא הקונפליקט. כשהקונפליקט גבוה, נורמליזציית דמפסטר עלולה לתת תוצאות לא-אינטואיטיביות (פרדוקס Zadeh).

```
from itertools import combinations
# מסגרת הבחנה: {F,A,D}; מסות מוקצות לתת-קבוצות (frozenset)
frame=['F','A','D']
subsets=[frozenset(s) for r in range(1,4) for s in combinations(frame,r)]
def ds_combine(m1,m2):
    out={}; K=0.0
    for B,mb in m1.items():
        for C,mc in m2.items():
            inter=B&C
            if inter: out[inter]=out.get(inter,0)+mb*mc
            else: K+=mb*mc
    return {k:v/(1-K) for k,v in out.items()}, K

# Fighter/Drone-אך משאיר בורות; חיישן 2 תומך ב-Fighter-חיישן 1 בטוח יחסית ב
m1={frozenset(['F']):0.6, frozenset(['F','A']):0.2, frozenset(frame):0.2}
m2={frozenset(['F']):0.5, frozenset(['D']):0.3, frozenset(frame):0.2}
comb,K=ds_combine(m1,m2)
print(f'קונפליקט K = {K:.3f}')
for s,v in sorted(comb.items(), key=lambda kv:-kv[1]):
    print(f' m({set(s)}) = {v:.3f}')
# Belief ו-Plausibility ל-{F}
A=frozenset(['F'])
bel=sum(v for s,v in comb.items() if s<=A)
pl=sum(v for s,v in comb.items() if s&A)
print(f'Bel(Fighter)={bel:.3f}, Pl(Fighter)={pl:.3f} (מרווח אי-הוודאות)')
```

$K = 0.240$ קונפליקט

$m(\{F\}) = 0.816$

$m(\{D\}) = 0.079$

$m(\{F, A\}) = 0.053$

$m(\{D, F, A\}) = 0.053$

$Bel(Fighter)=0.816, Pl(Fighter)=0.921$ (מרווח אי-הוודאות)

סיכום

- תכונות/מחלקה משפרות גם שיוך וגם זיהוי; היתוך בייסיאני צובר ביטחון על פני מדידות.
- תורת ההחלטה מאפשרת לשקלל עלויות שגיאה אסימטריות.
- Dempster-Shafer מייצג בורות במפורש; להיזהר מקונפליקט גבוה.

- בפועל, fusion מודרני משלב סיווג קינמטי+תכונתי (joint tracking & classification) – חיבור בין מחברות 03-04 לכאן.

08 - היסק מבוזר והיתוך מידע (Distributed Inference)

מלווה את ההרצאה: Pramod Varshney — Distributed Inference and Information Fusion

שקופיות הרצאה זו אינן ב-PDF. המחברת מבוססת על הספרות הקנונית של גילוי מבוזר (Varshney, Distributed Detection and Data Fusion, 1997).

בגילוי מבוזר, כל חיישן מקבל החלטה מקומית (ביט) ושולח אותה למרכז היתוך (fusion center) במקום את הנתון הגולמי — חוסך רוחב פס. השאלות: איזה כלל היתוך למרכז? ואיך נקבעים הספים המקומיים?

א. עקומת ROC ופשרת גילוי/אזעקת-שווא

כל חיישן מאופיין ב-

$$(P_D, P_{FA})$$

. עבור גילוי אות

$$A$$

ברעש גאוסיאני

$$\sigma$$

עם סף

$$\tau$$


:

$$P_{FA} = Q(\tau/\sigma), \quad P_D = Q((\tau - A)/\sigma), \quad Q(x) = \frac{1}{2}\text{erfc}(x/\sqrt{2})$$

ה-SNR קובע את עקומת ה-ROC — ככל שהיא גבוהה יותר (קרובה לפינה השמאלית-עליונה), הגילוי טוב יותר.

```
import numpy as np
import matplotlib.pyplot as plt
from math import erfc, sqrt
rng = np.random.default_rng(2)
Q = lambda x: 0.5*erfc(x/sqrt(2))
Qv = np.vectorize(Q)

taus = np.linspace(-2,8,300)
plt.figure(figsize=(6,5))
for A in [1.0, 2.0, 3.0]:
    pfa=Qv(taus); pd=Qv(taus-A)
    plt.plot(pfa,pd,label=f'SNR (A/σ)={A}')
plt.plot([0,1],[0,1], 'k:', label='ניחוש אקראי')
plt.xlabel('P_FA'); plt.ylabel('P_D'); plt.title('עקומות ROC'); plt.legend(); plt.grid(alpha=.3)
plt.tight_layout(); plt.show()
```



ב. כללי היתוך החלטות: OR / AND / רוב (k-out-of-N)

עם

N
חיישנים בלתי-תלויים מותנית, מרכז ההיתוך מחליט H_1 אם לפחות k

חיישנים דיווחו '1':

• **OR**)

$$k = 1$$

(— רגיש מאוד,

$$P_D$$

גבוה אך גם

$$P_{FA}$$

גבוה.

• **AND**)

$$k = N$$

(— שמרני,

$$P_{FA}$$

נמוך אך

$$P_D$$

נמוך.

$$k = \lfloor N/2 \rfloor$$

(— איזון.

$$P_D^{fus} = \sum_{i=k}^N \binom{N}{i} P_D^i (1 - P_D)^{N-i}$$

```
from math import comb
def kN(p, N, k): return sum(comb(N,i)*p**i*(1-p)**(N-i) for i in range(k,N+1))
N=5; pd, pfa = 0.6, 0.1
print(f'חיישן בודד: P_D={pd}, P_FA={pfa}')
for name,k in [('OR (1/5)',1),('רוב (3/5)',3),('AND (5/5)',5)]:
    print(f'{name:12s} P_D={kN(pd,N,k):.3f} P_FA={kN(pfa,N,k):.4f}')

ks=range(1,N+1)
plt.figure(figsize=(7,4))
plt.plot(list(ks),[kN(pd,N,k) for k in ks], 'o-', label='P_D מערכת')
plt.plot(list(ks),[kN(pfa,N,k) for k in ks], 's-', label='P_FA מערכת')
plt.xlabel('k (H1-כמה חיישנים נדרשים ל)'); plt.ylabel('הסתברות')
plt.title('k-out-of-N: פשרה בין גילוי לאזעקת שווא'); plt.legend(); plt.grid(alpha=.3)
plt.tight_layout(); plt.show()
```


חיישן בודד: P_D=0.6, P_FA=0.1

OR (1/5) P_D=0.990 P_FA=0.4095

רוב (3/5) P_D=0.683 P_FA=0.0086

AND (5/5) P_D=0.078 P_FA=0.0000

אווש תקעזאל יוליג יוב הרשפ: k-out-of-N ללכ



ג. כלל ההיתוך האופטימלי של Chair-Varshney

כשידועים

$$(P_{D,i}, P_{FA,i})$$

של כל חיישן, כלל ה-LRT האופטימלי משקלל כל החלטה מקומית
 $u_i \in \{0, 1\}$

לפי אמינותה:

$$\sum_i [u_i \ln \frac{P_{D,i}}{P_{FA,i}} + (1 - u_i) \ln \frac{1 - P_{D,i}}{1 - P_{FA,i}}] \leq \ln \frac{P_0}{P_1}$$

חיישנים אמינים יותר מקבלים משקל גדול יותר — בניגוד להצבעת רוב 'שווה'.

```
def chair_varshney(u, PD, PFA, P1=0.5):
    P0=1-P1; s=0.0
    for ui, pd, pf in zip(u, PD, PFA):
        s += np.log(pd/pf) if ui==1 else np.log((1-pd)/(1-pf))
    return 1 if s >= np.log(P0/P1) else 0

# 5 חיישנים הטרוגניים: חלקם אמינים, חלקם רועשים
PD=np.array([0.95,0.9,0.6,0.55,0.7])
PFA=np.array([0.02,0.05,0.3,0.4,0.2])
def majority(u): return 1 if sum(u)>=3 else 0

trials=20000; H1prob=0.5; cv_ok=maj_ok=0
for _ in range(trials):
    H=int(rng.random()<H1prob)
    u=[int(rng.random()<(PD[i] if H else PFA[i])) for i in range(5)]
    cv_ok += chair_varshney(u,PD,PFA)==H
    maj_ok+= majority(u)==H
print(f'דיוק הצבעת רוב: {maj_ok/trials:.1%}')
print(f'Chair-Varshney: {cv_ok/trials:.1%} (משקלל אמינות -> טוב יותר עם חיישנים הטרוגניים)')
```

דיוק הצבעת רוב : 93.5%

(משקלל אמינות -> טוב יותר עם חיישנים הטרוגניים) Chair-Varshney: 97.8% דיוק

ד. הקשר רחב: consensus וקונפידנס

- **Consensus / gossip** — צמתים ברשת ללא מרכז מתכנסים לאומד גלובלי דרך החלפות מקומיות בלבד.
- **קוונטיזציה** — שליחת ביטים ספורים במקום ערכים מלאים; פשרת רוחב-פס מול דיוק.
- **תקשורת לא-אמינה** — אובדן/השהיית הודעות מחייבים היתוך חסין. כל אלה הם הכללות מבוזרות של אותו עיקרון: **צבירת מידע מקטינה אי-ודאות** (משוואת ה-Fusion, מחברת 01).

סיכום

- **ROC** מאפיין כל חיישן; ה-SNR קובע את גבול הביצועים.
- כללי **k-out-of-N** (OR/רוב/AND) נותנים פשרות שונות בין

$$P_D$$

-ל

$$P_{FA}$$

• **Chair-Varshney** הוא כלל ההיתוך האופטימלי — משקלל לפי אמינות, עדיף על הצבעת רוב כשהחיישנים הטרוגניים.

09 • היתוך ברמה גבוהה (High-level Fusion)

מלווה את ההרצאה: High-level Fusion — Erik Blasch, FUSION Boot Camp 2026 (הרצאה 7).

שקופיות הרצאה 7 אינן ב-PDF, אך הרצאת המבוא של Blasch (מחברת 01) מכסה את היסודות. המחברת מבוססת עליהם ועל הספרות (Blasch, Bossé, Lambert, High-Level Information Fusion).

רמות **L0/L1** (מחברות 02-05) עוסקות בעצמים: היכן ומה. רמות **L2-L5** עוסקות במשמעות: מה המצב (situation), מה האיום (threat/impact), כיצד לכוון חיישנים (process refinement), ומה האדם צריך (user refinement).

א. תזכורת — רמות ה-JDL/DFIG הגבוהות

רמה שם	שאלה	טכניקות
L2 Situation Assessment	מה היחסים בין הישויות?	Bayesian nets, גרפים, ontologies
L3 Threat / Impact	מה ההשלכות והכוונה (intent)?	game theory, הסקה אבדוקטיבית
L4 Process Refinement	איך לכוון את החיישנים?	sensor management (מחברת 08)
L5 User Refinement	מה האדם צריך לראות/להחליט?	HMI, ויזואליזציה, הסבר

מאפיין מבדיל: ב-L2+ ההסקה היא אבדוקטיבית (ההסבר הסביר ביותר) ולעיתים **soft** (טקסט/דיווחי אדם), בניגוד להסקה הכמותית/hard ברמות הנמוכות.

ב. הערכת איום (Threat/Impact Assessment) — דוגמה מספרית

נדגים היתוך קינמטי + זהותי לדירוג איום. לכל מטרה נחשב מדד איום שמשלב:

• **CPA** (Closest Point of Approach) — כמה קרוב המסלול יעבור לנכס המוגן (קינמטי, מ-L1).

• **TTI** (Time-To-Intercept) — מתי (דחיפות).

• **P(hostile)** — הסתברות עוינות מהסיווג (מחברת 07). מדד האיום:

$$\text{threat} = P(\text{hostile}) \cdot f_{CPA} \cdot f_{TTI}$$

```
import numpy as np
import matplotlib.pyplot as plt
rng = np.random.default_rng(4)
asset = np.array([0.,0.]) # הנכס המוגן בראשית

def cpa_tti(pos, vel):
    """Closest Point of Approach (מרחק), יחסית לנכס בראשית (מרחק)"""
    r=pos-asset; v=vel
    if v@v < 1e-9: return np.linalg.norm(r), np.inf
    t=-(r@v)/(v@v); t=max(t,0.0)
    cpa=np.linalg.norm(r+v*t)
    return cpa, t
```

```
# חמש מטרות: מיקום, מהירות, הסתברות עוינות
tgtts=[
```

```

dict(name='T1', pos=np.array([100.,5.]), vel=np.array([-10.,0.]), p_host=0.9),
dict(name='T2', pos=np.array([80.,80.]), vel=np.array([-8.,-8.]), p_host=0.5),
dict(name='T3', pos=np.array([200.,2.]), vel=np.array([-5.,0.]), p_host=0.95),
dict(name='T4', pos=np.array([30.,60.]), vel=np.array([0.,-2.]), p_host=0.2),
dict(name='T5', pos=np.array([60.,3.]), vel=np.array([-12.,0.]), p_host=0.7),
]
for t in tgts:
    cpa,tti=cpa_tti(t['pos'],t['vel'])
    f_cpa=np.exp(-cpa/20.0) # קרוב יותר <- מסוכן יותר
    f_tti=np.exp(-tti/15.0) # מוקדם יותר <- דחוף יותר
    t['cpa'],t['tti'],t['threat']=cpa,tti,t['p_host']*f_cpa*f_tti

ranked=sorted(tgts,key=lambda d:-d['threat'])
print('דירוג איום (L3):')
for r,t in enumerate(ranked,1):
    print(f"{r}. {t['name']} threat={t['threat']:.3f} CPA={t['cpa']:.5.1f} TTI={t['tti']:.5.1f} P(host)={t['p_host']}")

```


דירוג איום (L3):

1.	T5	threat=0.432	CPA= 3.0	TTI= 5.0	P(host)=0.7
2.	T1	threat=0.360	CPA= 5.0	TTI= 10.0	P(host)=0.9
3.	T2	threat=0.257	CPA= 0.0	TTI= 10.0	P(host)=0.5
4.	T3	threat=0.060	CPA= 2.0	TTI= 40.0	P(host)=0.95
5.	T4	threat=0.006	CPA= 30.0	TTI= 30.0	P(host)=0.2

```

# (L2) ודירוג האיום (L3) ויזואליזציה של תמונת המצב
plt.figure(figsize=(7,6))
plt.plot(*asset,'b*',ms=20,label='נכס מוגן')
for t in tgts:
    p,v=t['pos'],t['vel']
    plt.scatter(*p,s=80+400*t['threat'],c=[t['threat'],0,1-t['threat']])
    plt.arrow(p[0],p[1],v[0]*4,v[1]*4,head_width=4,color='gray',alpha=.6)
    plt.annotate(f"{t['name']}\n{t['threat']:.2f}",p,textcoords='offset points',xytext=(6,6))
plt.title('גודל/אדום = איום גבוה\n(L3) הערכת איום + (L2) תמונת מצב');
plt.gca().set_aspect('equal')
plt.xlabel('x'); plt.ylabel('y'); plt.legend(); plt.grid(alpha=.3); plt.tight_layout();
plt.show()

```

ג. מדדי הערכה (MOP/MOE) — הקושי שהדגיש Blasch

Blasch מדגיש שהערכת מערכות fusion קשה (מורכבות, חסינות, יכולת-פעולה-הדדית). מבחינים בין:

• **MOP (Measures of Performance)** — מדדים טכניים נמוכי-רמה: RMSE,


$$P_D/P_{FA}$$

, זמן ריצה.

• **MOE (Measures of Effectiveness)** — האם המשימה הושגה: דיוק דירוג האיום, אזהרה בזמן, עומס

על המפעיל. מדד נפוץ לאיכות החלטה: שטח מתחת ל-ROC (AUC).

```
# MOE: (עם רעש סיווג Monte-Carlo) 'האם דירוג האיום שלנו מתאם לאיום ה'אמיתי'
def trial():
    order_est=[]; order_true=[]
    for t in tgts:
        p_obs=np.clip(t['p_host']+0.2*rng.standard_normal(),0,1) # סיווג רועש
        f_cpa=np.exp(-t['cpa']/20); f_tti=np.exp(-t['tti']/15)
        order_est.append(p_obs*f_cpa*f_tti)
        order_true.append(t['threat'])
    # Spearman-like: התאמת סדר העדיפויות
    re=np.argsort(np.argsort(-np.array(order_est)))
    rt=np.argsort(np.argsort(-np.array(order_true)))
    return np.corrcoef(re,rt)[0,1]
corrs=[trial() for _ in range(2000)]
plt.figure(figsize=(7,4)); plt.hist(corrs,bins=20,alpha=.7)
plt.axvline(np.mean(corrs),color='r',label=f'ממוצע={np.mean(corrs):.2f}')
plt.title('MOE: יציבות דירוג האיום תחת רעש סיווג'); plt.xlabel('מתאם דירוג'); plt.legend()
plt.grid(alpha=.3); plt.tight_layout(); plt.show()
```



ד. Hard + Soft Fusion והאדם בלולאה (L5)

fusion ברמה גבוהה משלב מקורות **hard** (חיישנים פיזיקליים) עם מקורות **soft** (דיווחי אדם, טקסט, מודיעין). Blasch מדגיש ש-fusion **אינו** מחליף הסקה אנושית אלא תומך בה (L5): הצגה, הסבר, ואינטראקציה. האתגרים הפתוחים שמנה במבוא: מידול **כוונה (intent)**, יריב **תגובתי אינטליגנטי**, וצורך **בבעיות אתגר משותפות** (common challenge problems) ובהערכה סטנדרטית להשוואה ושחזור.

סיכום

- רמות **L2-L5** עוברות מ'עצמים' ל'משמעות': מצב, איום, ניהול תהליך, ואדם בלולאה.
- הערכת איום משלבת **קינמטיקה (CPA/TTI)** עם **זהות (P(hostile))** — חיבור של מחברות 03-07.
- יש להבחין בין **MOP** (ביצועים טכניים) ל-**MOE** (הצלחת המשימה); הערכת fusion ברמה גבוהה נותרת קשה.
- היעד: **hard+soft fusion** התומך בהסקה אנושית — סגירת המעגל חזרה לעקרונות במחברת 01.